

# **DOKUMENTASI PEMBELAJARAN MESIN**

*"Penerapan Support Vector Machine (SVM)  
Pada Sistem Rekomendasi Minuman Starbucks"*



Disusun Oleh

Ivah Desty Tiurlina Purba (140707710)  
Yohanes Dwiki Witman Gusti Made (140707748)  
Satya Syahputra (150708332)  
Verryanto Paulus (150708524)

**PROGRAM STUDI TEKNIK INFORMATIKA  
FAKULTAS TEKNOLOGI INDUSTRI  
UNIVERSITAS ATMA JAYA YOGYAKARTA  
2018**

# **Penerapan Support Vector Machine (SVM) Pada Sistem Rekomendasi Minuman Starbucks**

Ivah Desty Tiurlina Purba<sup>1</sup>, Yohanes Dwiki Witman Gusti Made<sup>2</sup>,  
Satya Syahputra<sup>3</sup>, Verryanto Paulus<sup>4</sup>  
[140707710@students.uajy.ac.id](mailto:140707710@students.uajy.ac.id)<sup>1</sup>, [140707748@students.uajy.ac.id](mailto:140707748@students.uajy.ac.id)<sup>2</sup>,  
[140708332@students.uajy.ac.id](mailto:140708332@students.uajy.ac.id)<sup>3</sup>, [140708524@students.uajy.ac.id](mailto:140708524@students.uajy.ac.id)<sup>4</sup>

Program Studi Teknik Informatika  
Universitas Atma Jaya Yogyakarta, Indonesia

## **Abstrak**

Sistem penjualan moderen menggunakan algoritma tertentu untuk menyediakan pilihan produk yang tepat kepada penggunanya. Baru-baru ini, sistem penjualan minuman starbucks telah menggunakan algoritma pembelajaran mesin pada sistem rekomendasinya. Pada penelitian ini, kami mencoba untuk memperoleh model *Support Vector Machine* (SVM) yang tepat dari hasil belajar dataset Starbucks; 27 label, 6 atribut, dan 242 baris data.

Makalah ilmiah ini menyajikan tinjauan literatur yang sistematis untuk menganalisis pengaruh model SVM terhadap sistem rekomendasi minuman Starbucks dan mengidentifikasi peluang penelitian untuk pengembangan sistem selanjutnya. Studi ini menyimpulkan bahwa model SVM menghasilkan prediksi minuman dengan akurasi tes sebesar 71%, presisi 73%, recall 71%, f1-score 71%, support 49, dan rata-rata skor validasi silanginya sebesar 80%.

**Keywords:** *sistem, starbucks, rekomendasi, pembelajaran, svm, dataset, prediksi, skor*

## **1. PENDAHULUAN**

### **1.1 LATAR BELAKANG**

Sistem rekomendasi (SR) moderen membantu pengguna untuk memilih barang dan layanan, seperti buku, musik, makanan, bahkan rekomendasi orang melalui informasi pengguna dan produk yang direkomendasikan. SR berperan penting dalam membantu pengguna untuk memaksimalkan laba dan meminimalkan risiko.

SR muncul tahun 1990-an, awalnya menggunakan penyaringan kolaboratif pada profil pengguna. Saat ini SR berevolusi untuk memakai algoritma *machine-learning* (ML). ML telah ada sejak 1950-an dan banyak digunakan dalam aplikasi pengenalan

pola dan yang paling canggih adalah kendaraan yang mengemudi sendiri. Bisa dikatakan, potensi ML terlihat sangat menjanjikan saat ini.

Model ML dipakai SR untuk menyediakan rekomendasi yang lebih baik. Namun, bidang ML tidak memiliki klasifikasi algoritma yang jelas, karena pendekatan dan variasi algoritma yang berbeda-beda untuk jenis kasus dan data tertentu. Akibatnya, integrasi ML menjadi sulit dan membingungkan ketika memilih algoritma yang sesuai.

Namun begitu, gabungan SR dan ML dapat memperoleh manfaat yang luar biasa. Melalui algoritma ML, peneliti mungkin tidak tahu area mana yang bisa berdampak signifikan terutama kepada *end-user*. Salah

satunya membantu peneliti untuk meningkatkan hasil prediksi rekomendasi minuman starbucks. ML menekankan kepada probabilitas. Dalam hal ini, model ML memprediksi kemungkinan pengguna untuk memilih minuman yang tepat, sesuai inputan angka kandungan kafein, kalori, karbohidrat, kolesterol, protein, dan gula. Perlu identifikasi lebih lanjut untuk membantu peneliti dalam melihat hasil rekomendasi yang akurat dan arah pengembangan sistem selanjutnya.

Untuk alasan ini, peneliti memutuskan untuk melakukan tinjauan sistematis, yang menyelidiki seberapa nyata hasil rekomendasi dengan algoritma ML. Peneliti memakai algoritma *support vector machine* (svm) untuk melihat potensi dari algoritma ini dan pengaruhnya terhadap hasil rekomendasi minuman starbucks. Harapan peneliti, dari peninjauan sistematis ini, para pengembang sistem rekomendasi serupa dapat memperoleh informasi yang berguna dan bermanfaat.

## 1.2 LANDASAN TEORI

### 1.2.1 Sistem Rekomendasi

Sistem rekomendasi (SR) memberikan rekomendasi barang kepada pengguna. SR diperkenalkan pada tahun 1992 yaitu Tapestry, SR pertama yang memakai penyaringan kolaboratif untuk merujuk pada aktivitas rekomendasi berdasarkan profil pengguna.

SR dibagi menjadi tiga kategori utama: penyaringan kolaboratif, *content-based*, dan hibrida. SR menggunakan penyaringan kolaboratif untuk mempertimbangkan data pengguna saat rekomendasi. Misalnya profil pengguna, SR memiliki akses usia, negara, kota, dan minuman yang dibeli. SR berbasis konten memakai data item yang mereka

akses. Ketika pengguna menelusuri item tertentu, SR mengumpulkan informasi dengan cara mencarinya di database, yang memiliki atribut item serupa. SR bisa menggabungkan dua klasifikasi sebelumnya ke dalam pendekatan hibrida, rekomendasi berdasarkan data pengguna dan item.

### 1.2.2 Machine learning

Machine Learning (ML) menggunakan komputer untuk mensimulasikan pembelajaran manusia, mengidentifikasi, dan memperoleh pengetahuan dari dunia nyata, untuk meningkatkan kinerja tugas berdasarkan pengetahuan baru. Manusia secara alami belajar dari pengalaman dengan kemampuan berpikir, sebaliknya, komputer belajar dengan algoritma.

Saat ini, ada sejumlah besar algoritma ML. Mereka dapat diklasifikasikan dari pendekatan saat proses pembelajaran. Pada umumnya adalah pembelajaran yang diawasi (*supervised-learning*). Tugasnya yaitu belajar berdasarkan data pelatihan, dan menerapkan pengetahuan yang diperoleh pada data nyata. Data tersebut berupa satu set pelatihan (data pelatihan + jawaban) berupa tabel yang menghubungkan informasi data dengan klasifikasi yang benar.

### 1.2.3 Support Vector Machine

*Support Vector Machine* (SVM) adalah salah satu teknik ML yang pertama kali diperkenalkan oleh Boser, Guyon, dan Vapnik di COLT-92 pada tahun 1992. SVM digunakan untuk klasifikasi dan regresi dengan satu set metode pembelajaran yang diawasi (*supervised-learning*). SVM pada ML dipakai untuk memaksimalkan akurasi prediksi, dan menghindari *over-fitting* pada data.

SVM memaksimalkan jarak yang memisahkan elemen dari dua kelas

yang berbeda. SVM pada dasarnya menggunakan prinsip *Structural Risk Minimization* (SRM) yang lebih unggul dengan prinsip *Empirical Risk Minimization* (ERM), yang digunakan oleh jaringan saraf konvensional. Teknik ERM mencoba untuk meminimalkan kesalahan pada data pelatihan, tetapi SRM mencoba untuk meminimalkan batas atas pada risiko yang diharapkan dengan memaksimalkan pemisah *planes*. Perbedaan ini membuat SVM bekerja dengan kemampuan yang lebih baik untuk menyamaratakan data pelatihan dan membuat prediksi.


### 1.3 BATASAN MASALAH

Batasan masalah dari makalah ini adalah:

1. Hasil rekomendasi terbatas pada minuman starbucks dan rekomendasi produk meluas dengan Google.
2. Algoritma *machine-learning* yang digunakan adalah *support vector machine* (svm) varian svc.
3. Optimasi parameter GridSearchCV dipakai untuk meningkatkan hasil akurasi, presisi, recall, support, dan validasi silang.
4. Dataset Starbucks bersumber dari Kaggle, berupa kumpulan data nutrisi minuman starbucks seperti kandungan kafein, kalori, karbohidrat, kolesterol, protein, dan gula dalam bentuk csv.
5. Teknik *pre-processing* dipakai untuk meningkatkan kualitas dataset.

## 2. DATASET

Pembuatan dataset terdiri atas pemilihan dataset minuman starbucks, pembersihan dataset, pemilihan fitur/atribut yang tepat, transformasi dataset, dan reduksi dimensi dataset, untuk menjamin kualitas dataset sehingga mampu menghasilkan model terbaik dengan algoritma svm di bagian bab 3.



Gambar 2.1 Alur Pembuatan Dataset

### 2.1 Pemilihan Dataset & Library

Starbucks adalah jaringan kopi Amerika yang didirikan di Seattle. Starbucks melayani minuman dan makanan. Dataset Starbucks : <https://www.kaggle.com/starbucks/starbucks-menu/data> dan data yang diambil hanya data minuman saja.

Semua informasi gizi untuk minuman adalah untuk ukuran porsi 12 oz (1 cup = 340 gram = 12 oz = 12 ounce). Dataset ditentukan label minuman dan atributnya, seperti kafein, kalori, karbohidrat, kolesterol, protein, dan gula. Jumlahnya 27 label, 6 atribut, dan 242 baris, dalam bentuk .csv (*comma separated value*).

### 2.2 Data Cleaning

Pembersihan dataset dari nilai *null* dilakukan dengan perintah python di Jupyter Notebook: `dataset.isnull().values.any()` untuk mengecek semua value yang hilang atau tidak terisi.

Perintah python di Jupyter Notebook `dataset.fillna(value=mean)` yaitu mengisi nilai NaN dengan nilai variabel mean (rata-rata). Nilai mean sendiri bisa dicari melalui perintah rata-rata suatu kolom `dataset['nama_kolom'].mean()`.

Setelah itu, cek integrasi tipe data dari atribut dataset dengan perintah python di Jupyter: `dataset.dtypes`. Data angka namun tipenya umum (OBJECT) bisa diubah menjadi tipe yang numerik (FLOAT).

### 2.3 Data Selection

Seleksi dilakukan dengan perhitungan skor setiap atribut untuk mendapatkan *best-feature* dan *bad-feature*. Hal ini disebut *feature selection*. Melalui library *sklearn.feature\_selection*, peneliti memakai *SelectKBest* dan *chi2* untuk mendapat skor masing-masing atribut dan melakukan perangkingan.

Berdasarkan skornya, 3 atribut terbaik adalah Carbohydrates (6972), Caffeine (6779), dan Calories (6203). Atribut terburuk adalah Protein (458). Namun, peneliti tak ingin membuang atribut protein karena protein juga dipakai untuk menentukan kualitas kandungan (minuman yang sehat). Jadi tidak ada atribut yang dibuang di tahap ini.

### 2.4 Data Transformation

Dataset Starbucks berasal dari kumpulan angka yang jumlahnya besar dan dimensinya tinggi. Maka diperlukan tahap pre-processing pada dokumen dengan normalisasi.

Peneliti tahu ada banyak algoritma prediksi, tetapi semua hasilnya bisa sangat berbeda satu sama lain. Jadi untuk mempertahankan variansi prediksi antara atribut, teknik normalisasi diperlukan untuk membuat interval antara atribut yang lebih dekat.

Teknik *StandardScaler* berguna ketika membandingkan data yang sesuai dengan unit yang berbeda. Jika ingin menghapus unit dan melakukannya secara konsisten dari semua data, maka perlu mengubah data dengan menyatukan variansi (=1) dan menghilangkan nilai rata-ratanya (=0). *StandardScaler* mengubah data yang sedemikian rupa sehingga distribusinya memiliki nilai rata-rata 0 dan standar deviasi 1.

### 2.5 Data Reduction

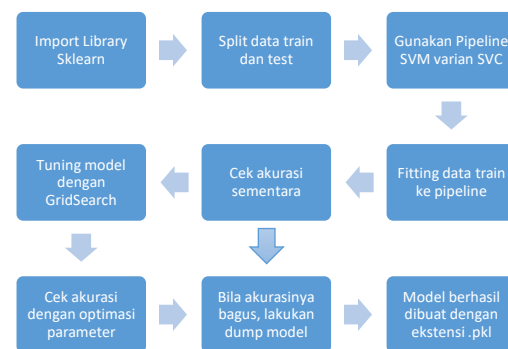
Reduksi dimensional dataset memakai algoritma seperti *Principal*

*Component Analysis* (PCA) untuk dataset yang jumlahnya besar. Namun, dataset starbucks hanya 242 baris. Peneliti simpulkan, representasi data dari komponen penyusunnya malah mengurangi informasi dan kualitas fitur, sebab representasi komponen penyusun jumlahnya sedikit.

Peneliti sudah mencoba menerapkan PCA, dengan mengambil dua komponen yang mendeskripsikan 90% variansi dataset. Akurasi yang dihasilkan pada pelatihan maupun tes tidak begitu bagus (31% dan 12%). Pada makalah ini, peneliti memutuskan tidak memakai reduksi dataset.

## 3. MODEL

Pembuatan model terdiri dari beberapa tahap, yaitu pemilihan library *sklearn*, split data, pemakaian SVM varian SVC, tuning model SVM, dan dump model.



Gambar 3.1 Alur Pembuatan ModelSVM

### 3.1 Pembelajaran dengan SVM

Pertama, lakukan import library *sklearn* lalu pisahkan data pelatihan (80%) dan tes (20%). Lalu, siapkan library SVM varian SVC untuk proses pembelajaran.

Kedua, lakukan fitting data pelatihan ke pipeline. Pipeline digunakan untuk mem-bundle algoritma atau kombinasinya menjadi satu, dalam hal ini algoritma SVM

dan hasil algoritma *pre-processing* di bab 2. Lalu cek akurasi modelnya.

Kadang kala akurasi yang dihasilkan tidak begitu bagus dan cenderung *under* atau *over fitting*. Solusinya adalah melakukan langkah *pre-processing* yang baik. Hal ini sudah dilakukan di bab 2. Cek kembali akurasi model, apakah langkah terakhir merupakan solusi terbaik untuk hasil akhir model.

### 3.2 Tuning Model SVM

Peneliti memperoleh model sementara yang akurasi tes sebesar 59% yaitu dengan `kernel='rbf'`, `C=100`, `Gamma=0.1`, dan `StandardScaler`. Hasil ini kurang layak untuk sistem rekomendasi. Maka perlu dilakukan *tuning* model dengan `GridSearchCV`.

`GridSearchCV` mencari *best-parameter* untuk objek `svm` dari dataset. Peneliti menemukan parameter terbaik yaitu dengan `kernel='linear'`, `C=243`, `Gamma=0.001`, dengan `StandardScaler`, `verbose=True`, dan `StratifiedKFold`-nya telah ditentukan; `n_splits=5`, `shuffle=True`, dan `random_state=5`. Awalnya, hasil rata-rata validasi silang `svm` sebesar 19%, tapi dengan *best-parameter* naik menjadi 80%.


### 3.3 Dump Model

Dump model dipakai untuk menyimpan hasil pembuatan model dimana hasil prediksinya sudah baik. Ekstensi model adalah `.pkl` dan bisa dibaca kembali untuk melakukan prediksi kedepannya.

## 4. PERCOBAAN DAN HASIL

Tahap percobaan sistem rekomendasi, API model, dan prediksi label berupa Query ke Google, yaitu menghasilkan rekomendasi produk. API menggunakan Flask, back-end menggunakan bahasa pemrograman PHP, dan front-end menggunakan *Material Design Google*.

Langkah - langkah pembuatannya sebagai berikut.



Gambar 4.1 Alur Pembuatan Sistem

### 4.1 Hasil API Model

API model `svm` memprediksi inputan parameter menggunakan layanan flask. API membaca `.pkl` untuk memberikan fungsi `Predict()`.

Route	Method	Fungsi	Param
/input /task	POST	Predict()	Calories (int) Cholesterol (int) Carbohydrates (int) Sugars (int) Protein (int) Caffeine (int)

Tabel 4.1 API Model

### 4.2 Hasil Back-end ke Google

Back-end mengambil hasil prediksi dari API model dan melakukan Query berdasarkan hasil prediksi (label minuman) ke Google.

### 4.3 Hasil Front-end Website

Halaman pertama website berisi 6 tempat input nilai, seperti jumlah parameter di API model. Halaman kedua menampilkan hasil rekomendasi berdasarkan nilai inputan pengguna. Halaman ketiga melakukan *re-direct* ke Google ketika pengguna melakukan klik *check-it-out!*

### 4.4 Hasil Rekomendasi Model SVM

Percobaan integrasi model SVM dan sistem rekomendasi minuman starbuck menghasilkan prediksi akurasi tes dengan akurasi tes sebesar 71%, presisi 73%, recall 71%, f1-score 71%, support 49, dan rata-rata skor validasi silang sebesar 80% (Lampiran 2).

Please fill attribute below

Caffeine	Calories
100	100

---

Carbohydrates	Cholesterol
100	100

---

Protein	Sugars
100	100

CHECK

Gambar 4.1 Pengisian Inputan Nutrisi Minuman

White Chocolate Mocha (Without Whipped Cream)

White Chocolate Mocha Pie - HungryHousewifePrinterVersion

Pour the hot cream mixture over the chocolate chips and let sit 5 minutes without stirring. After 5 minutes

Sugar free white chocolate mocha calories - Google Docs

Iced white chocolate mocha recipe I add vanilla syrup to the bottom and omit the. ... The white mocha cre

Sugar free white chocolate mocha nutrition - Google Docs

Iced white chocolate mocha recipe I add vanilla syrup to the bottom and omit the. ... with sugar free vanili

Gambar 4.2 Rekomendasi Minuman Berdasarkan Nilai Inputan Pengguna

frappuccino which is, in fact, not caffeinated. White ...

CHECK IT OUT!

Sugar free white chocolate mocha calories

White Mocha Substitute - Half the Calories!

[Get file.](#)

Gambar 4.3 Rekomendasi Minuman Ketika Pengguna Klik Check It Out!

## 5. KESIMPULAN

Hasil rekomendasi dengan *machine learning* model SVM berjalan cukup baik. Pemilihan dataset, pemilihan fitur (*feature scaling*), ekstraksi data (PCA), menghilangkan normalisasi (StandardScaler), menemukan *best-parameter* (GridSearchCV) semuanya telah dilakukan. Namun,

akurasi perlu ditingkatkan kembali. Diduga ada empat penyebab:

1. Dataset tidak perlu memiliki skala yang sama, karena dari Kaggle sudah ternormalisasi.
2. Dataset punya atribut yang tidak relevan dan bisa di dibuang (*drop-out*). Fitur protein skor *feature-selection* rendah(458). Harusnya dibuang.
3. Model perlu banyak pelatihan. Dataset hanya 242 baris data, terbagi menjadi set pelatihan (80%) dan test (20%).
4. Salah memilih algoritma atau urutan kerja kurang tepat.

## 6. DAFTAR PUSTAKA

- Alencar, P. (n.d.). The Use of Machine Learning Algorithms in Recommender Systems : A Systematic Review.
- K, A. A., & Aljahdali, S. (2013). Comparative Prediction Performance with Support Vector Machine and Random Forest Classification Techniques, 69(11), 12-16.
- Markov. (n.d.). Data Preprocessing. Retrieved from [http://www.cs.ccsu.edu/~markov/ccsu\\_courses/datamining-3.htm](http://www.cs.ccsu.edu/~markov/ccsu_courses/datamining-3.htm)
- Patro, S. G. K., & Kumar, K. (n.d.). Normalization : A Preprocessing Stage.
- Prokhorov, P. (n.d.). Titanic: kNN, PCA+SVM. Retrieved from <https://www.kaggle.com/pavelpster/titanic-knn-pca-svm>
- Seleting hyper-parameter C and gamma of a RBF-Kernel SVM. (n.d.). Retrieved from [http://ogrisel.github.io/scikit-learn.org/sklearn-tutorial/auto\\_examples/svm/plot\\_svm\\_parameters\\_selection.htm](http://ogrisel.github.io/scikit-learn.org/sklearn-tutorial/auto_examples/svm/plot_svm_parameters_selection.htm)
- Starbucks. (n.d.). Nutrition facts for Starbucks Menu. Retrieved <https://www.kaggle.com/starbucks/starbucks-menu/data>

**LAMPIRAN 1**  
**HASIL SEBELUM PERBAIKAN MODEL**

<b>Label</b>	<b>Precision (%)</b>	<b>Recall (%)</b>	<b>F1-Score (%)</b>	<b>Support (%)</b>
Banana Chocolate Smoothie	0.50	1.00	0.67	1
Brewed Coffee	0.50	1.00	0.67	1
Caffè Americano	0.00	0.00	0.00	1
Caffè Latte	0.00	0.00	0.00	2
Caffè Mocha (Without Whipped Cream)	1.00	0.50	0.67	2
Cappuccino	0.50	0.50	0.50	2
Caramel	0.20	0.50	0.29	1
Caramel (Without Whipped Cream)	0.20	0.50	0.29	2
Caramel Apple Spice (Without Whipped Cream)	1.00	1.00	1.00	1
Caramel Macchiato	0.00	0.00	0.00	2
Coffee	0.00	0.00	0.00	2
Hot Chocolate (Without Whipped Cream)	0.50	0.50	0.50	2
Iced Brewed Coffee (With Classic Syrup)	0.00	0.00	0.00	1
Iced Brewed Coffee (With Milk & Classic Syrup)	1.00	1.00	1.00	2
Java Chip	1.00	1.00	1.00	1
Java Chip (Without Whipped Cream)	1.00	0.50	0.00	2
Mocha	0.00	0.00	0.00	1
Mocha (Without Whipped Cream)	0.00	0.00	0.00	2
Orange Mango Banana Smoothie	1.00	1.00	1.00	1
Shaken Iced Tazo® Tea (With Classic Syrup)	0.33	1.00	0.5	1
Shaken Iced Tazo® Tea Lemonade (With Classic Syrup)	0.00	0.00	0.00	1
Skinny Latte (Any Flavour)	0.00	0.00	0.00	1
Strawberries & Crème (Without Whipped Cream)	0.67	1.00	0.80	2
Strawberry Banana Smoothie	1.00	1.00	1.00	1
Tazo® Chai Tea Latte	1.00	1.00	1.00	2
Tazo® Full-Leaf Red Tea Latte (Vanilla Rooibos)	0.00	0.00	0.00	2
Tazo® Full-Leaf Tea Latte	0.33	0.50	0.40	2
Tazo® Green Tea Latte	1.00	0.50	0.67	2
Tazo® Tea	1.00	1.00	1.00	1
Vanilla Bean (Without Whipped Cream)	0.00	0.00	0.00	1
Vanilla Latte (Or Other Flavoured Latte)	0.00	0.00	0.00	2
White Chocolate Mocha (Without Whipped Cream)	1.00	1.00	1.00	2
<b>Avg / total (%)</b>	<b>0.46</b>	<b>0.47</b>	<b>0.44</b>	<b>49</b>
<b>Rate (%) of Cross Validation Score [SVM] : 0.19</b>				



**LAMPIRAN 2**  
**HASIL SESUDAH PERBAIKAN MODEL**

<b>Label</b>	<b>Precision (%)</b>	<b>Recall (%)</b>	<b>F1-Score (%)</b>	<b>Support (%)</b>
Banana Chocolate Smoothie	1.00	1.00	1.00	1
Brewed Coffee	1.00	1.00	1.00	1
Caffè Americano	1.00	1.00	1.00	1
Caffè Latte	0.33	0.50	0.40	2
Caffè Mocha (Without Whipped Cream)	0.67	1.00	0.80	2
Cappuccino	1.00	0.50	0.67	2
Caramel	0.00	0.00	0.00	1
Caramel (Without Whipped Cream)	0.67	1.00	0.80	2
Caramel Apple Spice (Without Whipped Cream)	1.00	1.00	1.00	1
Caramel Macchiato	1.00	0.50	0.67	2
Coffee	0.25	0.50	0.33	2
Hot Chocolate (Without Whipped Cream)	1.00	1.00	1.00	2
Iced Brewed Coffee (With Classic Syrup)	1.00	1.00	1.00	1
Iced Brewed Coffee (With Milk & Classic Syrup)	1.00	1.00	1.00	2
Java Chip	1.00	1.00	1.00	1
Java Chip (Without Whipped Cream)	1.00	1.00	1.00	2
Mocha	0.00	0.00	0.00	1
Mocha (Without Whipped Cream)	1.00	0.50	0.67	2
Orange Mango Banana Smoothie	1.00	1.00	1.00	1
Shaken Iced Tazo® Tea (With Classic Syrup)	1.00	1.00	1.00	1
Shaken Iced Tazo® Tea Lemonade (With Classic Syrup)	1.00	1.00	1.00	1
Skinny Latte (Any Flavour)	0.00	0.00	0.00	1
Strawberries & Crème (Without Whipped Cream)	1.00	1.00	1.00	2
Strawberry Banana Smoothie	1.00	1.00	1.00	1
Tazo® Chai Tea Latte	1.00	1.00	1.00	2
Tazo® Full-Leaf Red Tea Latte (Vanilla Rooibos)	0.00	0.00	0.00	2
Tazo® Full-Leaf Tea Latte	0.00	0.00	0.00	2
Tazo® Green Tea Latte	1.00	1.00	1.00	2
Tazo® Tea	1.00	1.00	1.00	1
Vanilla Bean (Without Whipped Cream)	0.00	0.00	0.00	1
Vanilla Latte (Or Other Flavoured Latte)	0.50	0.50	0.50	2
White Chocolate Mocha (Without Whipped Cream)	1.00	1.00	1.00	2
<b>Avg / total (%)</b>	<b>0.73</b>	<b>0.71</b>	<b>0.71</b>	<b>49</b>
<b>Acc: 0.71, Rate (%) of Cross Validation Score [SVM] : 0.80</b>				